TECNOLÓGICO DE ESTUDIOS SUPERIORES DE IXTAPALUCA

INGENIERÍA EN SISTEMAS COMPUTACIONALES

REDES NEURONALES ARTIFICIALES

Segundo parcial · Actividad 1

DEL PERCEPTRÓN A LA RETROPROPAGACIÓN

Investigación y análisis teórico

Docente:

Ing. Esteban Ramírez de la Rosa

Integrantes:

Espitia Zavala Gerardo

Olvera Rodríguez Bruno

Semestre: 9.º Grupo: 1951

Octubre de 2026

SISTEMA DE GESTIÓN INTEGRAL ISO 21001:2018 Y 14001:2015 **Nombre del formato: Instrumento de Evaluación (Lista de Cotejo)**	Código: FOR-GA-TESI-07-G Edición: 1 Revisión: 1 Fecha de emisión: 01 de agosto de 2025 Fecha de Actualización: 01 de agosto de 2025

Objetivo: Evaluar las evidencias de aprendizaje mediante un instrumento que indica diversas características que debe cumplir

Asignatura:	Redes neuronales artificiales	**Clave SCD - 1003**	
Docente:	Ing. Esteban Ramírez De la Rosa	**Grupo:**	
Alumno (a):	1-		
	2-		
	3-		
	4-	**Matrícula:**	
Semestre:	**Fecha de aplicación:**	**Duracíon de la acividad:**	
Tema (s):	**Redes Neuronales Artificiales (Unidades 2 y 3)**		

LISTA DE COTEJO	
Competencia (s) Específica (s):	Conocer los antecedentes históricos de las Redes Neuronales Artificiales (RNA) y su relación con los sistemas nerviosos biológicos, identificando sus elementos, procesos de aprendizaje, alcances y limitaciones.

Instrucciones:
1. El docente marcará con una "X" en la columna de **SI** o **NO**, según corresponda, en función de las características de la actividad realizada y asignara el puntaje en la columna de "Puntos".
2. El docente realizará a sumatoria de los puntos y colocará la cifra en el apartado de "Puntos obtenidos".
3. El docente y el alumno firman de conformidad con el puntaje obtenido.

Núm.	Ítem El (instrumento de evaluación):	Valor	Indicador	SI	NO	Puntos
1	**Investigación Teórica (Actividad 1)** Claridad en la explicación del Perceptrón, XOR y Multicapa. Explica con precisión técnica la regla de Rosenblatt y la limitación lineal del XOR. Justifica la necesidad de capas ocultas con ejemplos claros.	20				
2	**Caso de Aplicación Real (Actividad 1)** Búsqueda y síntesis de un artículo técnico sobre MLP. Selecciona un artículo relevante (Q1/Q2 o IEEE/ACM). Resume correctamente la arquitectura, el problema y los resultados, citando adecuadamente.	10				
3	**Calidad del Documento (Actividad 1)** Redacción, ortografía y citas APA. Documento impecable, bien estructurado, sin errores ortográficos. Citas en formato APA correctas.	10				
4	**Implementación del Código (Actividad 2)** Correcta implementación del Forward Pass y Backpropagation. El código funciona sin errores. Implementa correctamente el cálculo de gradientes y la actualización de pesos (o usa correctamente el framework). Comentarios claros.	25				
5	**Experimentación y Gráficas (Actividad 2)** Curvas de aprendizaje y comparación de hiperparámetros. Presenta al menos 2 experimentos claros. Las gráficas (Loss vs Épocas) están correctamente etiquetadas y muestran el efecto de la tasa de aprendizaje.	15				
6	**Análisis de Resultados (Actividad 2)** Interpretación de la convergencia y el sobreajuste. Analiza críticamente si hubo convergencia, menciona el overfitting/underfitting y relaciona los resultados con la teoría de la Unidad 3.	10 pts				
7	**Trabajo en Equipo y Presentación (Actividad 2)** Claridad del reporte y colaboración (si aplica). Reporte profesional, estructurado (Intro, Metodología, Resultados, Conclusiones). Se evidencia trabajo colaborativo.	10 pts				

Puntaje máximo:	100	**Puntaje Mínimo:**	50	**Puntaje Obtenido:**	

Retroalimentación:

		Indicadores						Método de Evaluación			
Evidencia de aprendizaje	**%**	**A**	**B**	**C**	**D**	**E**	**F**	**Instrumento de evaluación**	**P**	**C**	**A**
Lista de Cotejo	50	10	10	10	5	5	10	Lista de cotejo	x	x	x

Nombre y firma del docente: Ing. Esteban Ramirez De la Rosa

Nombre y firma del alumno (a): _____

GOBIERNO DEL ESTADO DE MÉXICO

TESI TECNOLÓGICO DE ESTUDIOS SUPERIORES IXTAPALUCA

Evaluación 2do parcial. **Ciclo escolar:** **Fecha:** _____
Materia: Redes neuronales **Carrera: I.S.C** **Grupo:** _____
Alumno: **Prof. Ing. Esteban Ramírez De la Rosa.** **Calificación:** _____

No. De Aciertos.	Evaluación de proyecto	Calificaciones extras	Calificación	Firma.

La presente evaluación se desarrollará en equipos de **cuatro integrantes**, los cuales se formarán por decisión de los propios estudiantes, considerando los siguientes criterios.

Actividad de Evaluación: Redes Neuronales Artificiales (Unidades 2 y 3)
Del Perceptrón a la Retropropagación

Materia: Redes Neuronales Artificiales
Puntaje Total: 100 puntos
Modalidad: En equipo (Implementación)

Objetivo: Analizar los fundamentos teóricos del Perceptrón y las limitaciones que llevaron al desarrollo de redes multicapa, así como implementar y evaluar el algoritmo de retropropagación en un problema práctico.

Instrucciones Generales: La actividad se divide en dos. La actividad 1 (Investigación Teórica) es en equipo para investigar y profundizar en los conceptos de la Unidad 2. La actividad 2 (Implementación Práctica) es en equipo y se enfoca en la Unidad 3, requiriendo el diseño y entrenamiento de una red neuronal.

ACTIVIDAD 1: Investigación y Análisis Teórico (40 Puntos)

Formato: Documento PDF (Máximo 5 páginas) con citas en formato APA.

Investigar y redactar un análisis crítico sobre la evolución de los modelos de aprendizaje supervisado, abordando específicamente:

El Perceptrón Simple (Unidad 2): Explica su arquitectura, la regla de aprendizaje de Rosenblatt y el concepto de separabilidad lineal como la explicación de su diagrama.

La Limitación del XOR: Detalla el problema de la función lógica XOR y por qué un Perceptrón simple no puede resolverlo (justifica matemáticamente o gráficamente).

El Salto a la Multicapa (Unidad 3): Explica cómo la introducción de capas ocultas y funciones de activación no lineales resuelven el problema anterior.

Aplicación Real: Busca dos artículos científicos o caso técnico (de los últimos 5 años) donde se utilice una red neuronal multicapa (MLP) o de retropropagación para resolver un problema de clasificación o regresión. Resume el problema, la arquitectura usada y los resultados obtenidos.

Entregable: Documento con introducción, desarrollo, conclusiones y referencias.

Actividad 2: Implementación y Experimentación (60 Puntos)
Modalidad: **En equipo**
Formato: **Código fuente (Python/Google Colab) + Reporte de Resultados (PDF).**
Se deberán implementar (usando librerías como NumPy, TensorFlow o PyTorch) una red neuronal multicapa y experimentar con el algoritmo de retropropagación.

GOBIERNO DEL ESTADO DE MÉXICO
TESI TECNOLÓGICO DE ESTUDIOS SUPERIORES IXTAPALUCA

Escenario Práctico:

Selecciona uno de los siguientes problemas para resolver:

Opción 1: Clasificación de la compuerta lógica XOR (mínimo 1 capa oculta).

Opción 2: Clasificación de dígitos manuscritos (usando un subconjunto de MNIST o un dataset similar disponible en línea).

Tareas a realizar:

Diseño de la Arquitectura: Definan el número de capas, el número de neuronas por capa y la función de activación (justifiquen su elección).

Entrenamiento: Implementen el ciclo de entrenamiento (Forward Pass, Cálculo de Error, Backpropagation, Actualización de Pesos).

Experimentación: Realicen al menos dos experimentos variando la tasa de aprendizaje (learning rate) o el número de épocas. Grafiquen la curva de pérdida (Loss) vs. Épocas para ambos casos.

Análisis: Expliquen qué sucedió con la convergencia. ¿Hubo sobreajuste (overfitting)? ¿Cómo afectó la tasa de aprendizaje al proceso?

Entregable: Enlace (link) al cuaderno de Colab (con permisos de edición) o archivo .py comentado, junto con un reporte de 2-3 páginas con las gráficas y conclusiones.

NOTA:

1. La entrega de la documentación será el día **jueves 29 de octubre** en horario de clase.
2. Anexar este formato como la rúbrica de avaluación a su documentación después de la caratula.
3. Los documentos deberán tener nombre y apellidos de los integrantes del equipo (legible) como firma, en tinta Azul, no se aceptará colores al mencionado.
4. Cualquier petición de reemplazo o incorporación de un nuevo integrante al equipo deberá ser comunicada al docente con una antelación mínima de quince días naturales previos a la fecha establecida para la entrega del trabajo, de no notificar dicha situación no se podrá realizar.

Nombre y firma Integrantes del equipo:

1.-_____ **Represéntate de equipo.**

2.-_____

3.-_____

4.-_____

La integración del equipo se formalizará mediante la firma de sus miembros y el sello del docente.

ÍNDICE DE CONTENIDO

INTRODUCCIÓN (I) 6
JUSTIFICACIÓN 6
OBJETIVOS 6
1. PERCEPTRÓN SIMPLE Y REGLA DE ROSENBLATT 6
2. LIMITACIÓN DE LA FUNCIÓN XOR 7
3. REDES MULTICAPA Y RETROPROPAGACIÓN 8
4. ESTUDIOS CIENTÍFICOS DE APLICACIÓN (2024) 9
5. CONCLUSIONES INDIVIDUALES 10
REFERENCIAS 11

ÍNDICE DE IMÁGENES

Figura 1. Esquema conceptual del perceptrón simple 6
Figura 2. Distribución lógica de XOR 7
Figura 3. Arquitectura multicapa propuesta para XOR 8

INTRODUCCIÓN

Las redes neuronales artificiales aprenden relaciones entre entradas y salidas. El perceptrón simple utiliza fronteras lineales, pero funciones como XOR requieren transformaciones no lineales. Esta investigación explica la regla de Rosenblatt, demuestra la limitación de XOR y describe cómo las capas ocultas y la retropropagación superan esa restricción.

JUSTIFICACIÓN

XOR conecta fundamentos matemáticos y programación en Python con cuatro ejemplos verificables. Su estudio ayuda a distinguir las limitaciones de arquitectura de las dificultades del entrenamiento y permite relacionar la teoría con aplicaciones recientes.

OBJETIVOS

Objetivo general. Analizar la evolución del perceptrón simple hacia las redes neuronales multicapa, explicando la separabilidad lineal y el papel de la retropropagación mediante el caso de la función XOR.

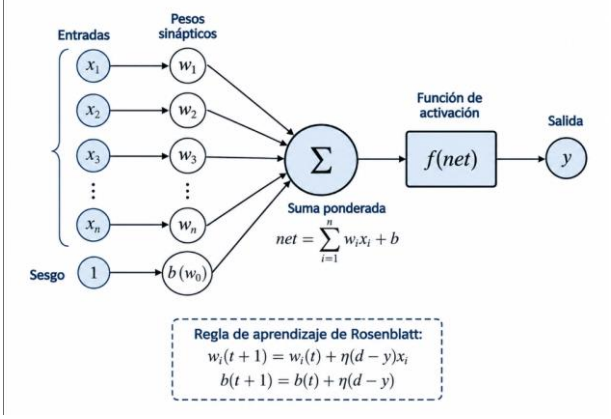
Objetivos específicos. (1) Describir la estructura y la regla de aprendizaje del perceptrón; (2) demostrar la imposibilidad de clasificar XOR con una sola frontera lineal; (3) explicar las capas ocultas, activaciones y actualización de pesos; y (4) examinar dos aplicaciones científicas recientes.

1. PERCEPTRÓN SIMPLE Y REGLA DE ROSENBLATT

El perceptrón recibe entradas $x_1, \ldots, x_n$; a cada una le asigna un peso w_i, suma un sesgo b y calcula $z = \Sigma(w_i x_i) + b$. Una función escalón produce la clase predicha: $\hat{y} = 1$ si $z \geq 0$ y $\hat{y} = 0$ en caso contrario. Su superficie de decisión, $w \cdot x + b = 0$, es una recta en dos dimensiones (Rosenblatt, 1958).

Figura 1. Esquema conceptual del perceptrón simple

Figura 1. Esquema conceptual del perceptrón simple



La regla supervisada de actualización es $w_i \leftarrow w_i + \eta(y - \hat{y})x_i$ y $b \leftarrow b + \eta(y - \hat{y})$, con $\eta > 0$ como tasa de aprendizaje. Si los ejemplos son separables linealmente, el algoritmo de perceptrón puede encontrar una frontera que los clasifique; si no lo son, no existe una elección de pesos y sesgo capaz de clasificarlos perfectamente.

2. LIMITACIÓN DE LA FUNCIÓN XOR

XOR (OR exclusivo) vale uno cuando las entradas binarias son diferentes y cero cuando son iguales. Sus cuatro combinaciones son (0,0)→0, (0,1)→1, (1,0)→1 y (1,1)→0. En el plano, los puntos positivos ocupan esquinas opuestas; una única recta no puede separarlos de ambos puntos negativos.

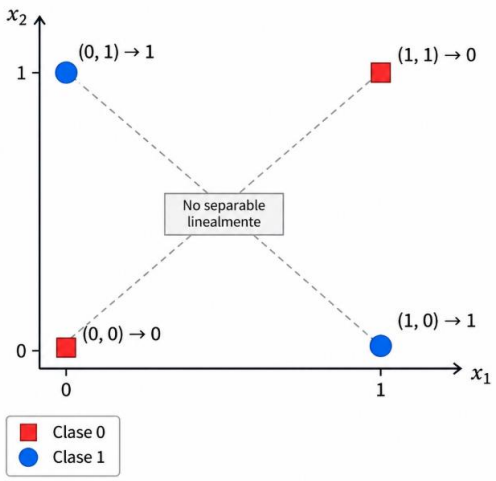
Figura 2. Distribución lógica de XOR

Demostración matemática. Si el perceptrón usa la condición $w_1x_1 + w_2x_2 + b \geq 0$ para predecir 1, las etiquetas XOR exigen simultáneamente: $b < 0$ para (0,0); $w_2 + b \geq 0$ para (0,1); $w_1 + b \geq 0$ para (1,0); y $w_1 + w_2 + b < 0$ para (1,1).

Al sumar las dos desigualdades positivas se obtiene $w_1 + w_2 + 2b \geq 0$, es decir, $w_1 + w_2 + b \geq -b$. Como $b < 0$, resulta $-b > 0$ y, por tanto, $w_1 + w_2 + b > 0$, lo cual contradice la cuarta condición. Ninguna combinación de pesos y sesgo satisface los cuatro casos. La limitación es de representación del modelo, no simplemente de tiempo de entrenamiento.

Modificar la tasa de aprendizaje no elimina la frontera lineal: XOR requiere una arquitectura capaz de representar decisiones no lineales (Minsky & Papert, 1969).

Figura 2. Distribución lógica de XOR



Nota: Las clases positivas y negativas no pueden separarse con una sola recta.

3. REDES MULTICAPA Y RETROPROPAGACIÓN

Un perceptrón multicapa (MLP) contiene una capa de entrada, una o más capas ocultas y una capa de salida. En cada capa se aplica una transformación afín seguida de una función de activación: $a^{(l)} = f(W^{(l)}a^{(l-1)} + b^{(l)})$. Funciones no lineales como sigmoide, tanh o ReLU evitan que la composición de capas se reduzca a otra transformación lineal. Para XOR se propone la arquitectura 2–2–1: dos entradas, dos neuronas ocultas y una salida sigmoide.

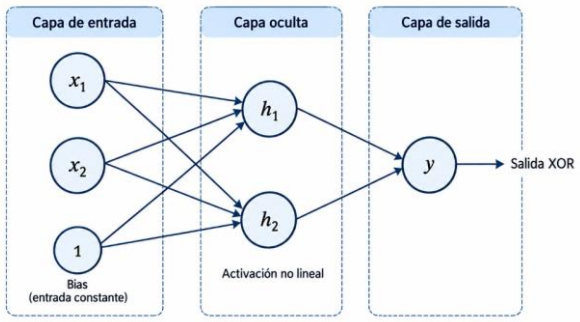
Figura 3. Arquitectura multicapa propuesta para XOR

Una demostración constructiva usa neuronas ocultas de tipo escalón para calcular $h_1 = OR(x_1,x_2)$ y $h_2 = NAND(x_1,x_2)$; la salida obtiene $AND(h_1,h_2)$, equivalente a XOR. Por ejemplo: $h_1 = H(x_1+x_2-0.5)$; $h_2 = H(-x_1-x_2+1.5)$; $\hat{y} = H(h_1+h_2-1.5)$, donde $H(z)=1$ si $z\geq 0$. Esta construcción muestra la capacidad representacional de una capa oculta; para entrenar mediante gradientes se prefieren activaciones diferenciables o subdiferenciables.

En el paso hacia adelante (forward pass) la red obtiene ŷ; después se calcula una función de pérdida L(y, ŷ), por ejemplo entropía cruzada binaria. La retropropagación aplica la regla de la cadena para calcular ∂L/∂W y ∂L/∂b desde la salida hasta las capas anteriores. Finalmente, el descenso por gradiente actualiza $W \leftarrow W - \eta \partial L/\partial W$ y $b \leftarrow b - \eta \partial L/\partial b$. Este procedimiento se popularizó para redes multicapa gracias a Rumelhart et al. (1986).

La tasa de aprendizaje controla el tamaño de cada actualización y las épocas son pasadas completas por los datos. En la Actividad 2 se compararán tasas mediante curvas de pérdida. Por tener solo cuatro casos, XOR no permite demostrar generalización a datos externos.

Figura 3. Arquitectura multicapa propuesta para XOR



Una capa oculta permite resolver el problema no lineal de XOR.

4. ESTUDIOS CIENTÍFICOS DE APLICACIÓN (2024)

Caso 1. Przybyła-Kasperek y Marfo (2024), PLOS ONE. Problema: clasificar registros tabulares distribuidos entre distintas fuentes, con atributos no idénticos. Arquitectura: varias redes MLP locales entrenadas con las tablas disponibles; sus predicciones se combinan mediante agregación ponderada y se reentrena un modelo global con objetos compartidos. Resultados: los autores reportan una mejora promedio de 15 % en exactitud y 12 % en exactitud balanceada frente a los métodos de comparación. Esos porcentajes son mejoras relativas reportadas en su evaluación, no una exactitud universal. La principal diferencia respecto de XOR

es la heterogeneidad y complejidad de datos reales (Przybyła-Kasperek & Marfo, 2024).

Caso 2. Debbarma et al. (2024), comunicación IEEE. Problema: clasificación de conjuntos de datos de diagnóstico y del conjunto Iris. Arquitectura: perceptrón multicapa entrenado con una estrategia que combina retropropagación y el optimizador Prairie Dog Optimization (PDO), comparada con métodos de optimización alternativos. Resultados reportados: 97.30 % de exactitud en Iris, 82.6 % en diabetes y 96.41 % en cáncer de mama. El registro bibliográfico consultado no permite confirmar la cantidad exacta de neuronas de cada capa; por ello no se atribuye una configuración numérica no verificada. Estos valores pertenecen a conjuntos distintos y no deben compararse directamente entre sí (Debbarma et al., 2024).

Análisis crítico. Ambos estudios ilustran que el MLP es una familia de modelos adaptable, no una arquitectura fija. El primero prioriza la integración de información dispersa y el segundo modifica la optimización del entrenamiento. Su desempeño no depende exclusivamente del uso de capas ocultas: influye la preparación de datos, la estrategia de entrenamiento, el protocolo de prueba y la métrica elegida. La función XOR es un punto de partida didáctico, no una validación de rendimiento en aplicaciones clínicas o industriales.

5. CONCLUSIONES INDIVIDUALES

Espitia Zavala Gerardo. El análisis de XOR me permitió entender que un perceptrón simple puede aprender reglas lineales, pero no todas las relaciones lógicas. La contradicción entre desigualdades demuestra que el problema no se corrige entrenando durante más tiempo. Considero que conocer primero la capacidad de la arquitectura es indispensable antes de ajustar sus parámetros en Python.

Olvera Rodriguez Bruno. Identifiqué que las capas ocultas, junto con activaciones no lineales, permiten representar funciones que un perceptrón no puede resolver. También comprendí que la retropropagación no es una arquitectura, sino el

procedimiento que transmite gradientes y ayuda a modificar los pesos. Los artículos muestran por qué deben evaluarse tanto el diseño de la red como los resultados.

REFERENCIAS

Debbarma, T., Shaikh, A., Tarafdar, A., Baidya, A., Majumder, P., & Bera, U. K. (2024). Enhancing multi-layer perceptron training with Prairie Dog Optimizer: Advancing classification accuracy in medical diagnostics. IEEE. https://doi.org/10.1109/SILCON63976.2024.10910597

Minsky, M., & Papert, S. (1969). Perceptrons: An introduction to computational geometry. MIT Press.

Przybyła-Kasperek, M., & Marfo, K. F. (2024). A multi-layer perceptron neural network for varied conditional attributes in tabular dispersed data. PLOS ONE, 19(12), e0311041. https://doi.org/10.1371/journal.pone.0311041

Rosenblatt, F. (1958). The perceptron: A probabilistic model for information storage and organization in the brain. Psychological Review, 65(6), 386–408. https://doi.org/10.1037/h0042519

Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). Learning representations by back-propagating errors. Nature, 323, 533–536. https://doi.org/10.1038/323533a0

Declaración de apoyo tecnológico: se utilizó ChatGPT (OpenAI) como apoyo para la creación de las imágenes.